

Practical Assignment

Start

Aprendizagem computacional I 24/25



Maria inês Rocha 202305626
Matilde Morais 202304849

Machine Learning I



1

2

3

4

5

6

7

8

9

10

Sumário

Resumo: Adaptação do KNN para Classes Desequilibradas

Objetivo Principal: Melhorar o desempenho do algoritmo KNN em datasets de classificação binária com classes desequilibradas.

Abordagem:

- Implementação Base: KNN
- Análise: Investigação do impacto do desequilíbrio de classes no KNN.
- Proposta: Criação de uma variante do KNN para a decisão da classe.
- Avaliação: Comparação da performance do KNN básico vs. KNN modificado em datasets do "Dataset Group 2", utilizando métricas como balanced accuracy.

Sumário dos Resultados: A implementação do KNN com thresholding demonstrou uma melhoria significativa na performance em cenários de classes desequilibradas. Esta abordagem permitiu ao modelo classificar de forma mais eficaz as instâncias da classe minoritária, mitigando o impacto negativo do desequilíbrio e resultando em melhores valores nas métricas de avaliação selecionadas em comparação com o KNN original.



1

2

3

4

5

6

7

8

9

10

Descrição do Algoritmo (KNN)

- O **algoritmo K-Nearest Neighbors** (KNN) é um método de aprendizagem supervisionada baseado em instâncias, utilizado tanto para classificação como para regressão.
- A sua lógica fundamental consiste em classificar um novo ponto de dados com base na classe (ou valor, no caso da regressão), predominante entre os seus 'k' vizinhos mais próximos no espaço de features.
- A "proximidade" é geralmente calculada utilizando uma métrica de distância, como a distância Euclidiana.
- O KNN é considerado um algoritmo "lazy learner" porque não constrói um modelo explícito durante a fase de treino, em vez disso, armazena todo o dataset de treino e realiza os cálculos apenas no momento da predição.
- É um algoritmo simples de implementar, mas a sua performance pode ser sensível à escolha de 'k', à métrica de distância utilizada e às características dos dados.

Comportamento do KNN face ao Desequilíbrio de Classes

O **desequilíbrio de classes** é uma característica dos dados que afeta significativamente o desempenho do KNN. O algoritmo toma decisões com base na maioria entre os 'k' vizinhos mais próximos. Num dataset desequilibrado, a classe maioritária, por ter uma representação muito superior, tende a dominar a vizinhança da maioria das instâncias.



1

2

3

4

5

6

7

8

9

10

Comportamento e Implicações:

- **Tendência para a Classe Maioritária:** Quando um novo ponto é avaliado, é mais provável que a maioria dos seus 'k' vizinhos pertençam à classe maioritária, simplesmente devido à sua maior densidade no espaço de features. Isto leva o KNN a classificar incorretamente instâncias da classe minoritária como pertencentes à classe maioritária.
- **Baixa Sensibilidade à Classe Minoritária:** O algoritmo pode apresentar uma alta accuracy geral (devido à correta classificação da classe maioritária), mas um péssimo desempenho na identificação de instâncias da classe minoritária (baixo recall ou sensibilidade para a classe minoritária).
- **Impacto da Escolha de 'k':**
 - Valores pequenos de 'k' podem tornar o modelo mais sensível ao ruído e a outliers, mas também podem capturar melhor pequenas regiões da classe minoritária.
 - Valores grandes de 'k' tendem a suavizar as fronteiras de decisão, o que pode agravar o problema do desequilíbrio, pois a influência da classe maioritária torna-se ainda mais dominante na vizinhança.

Em suma, o KNN, ao tratar todas as classes e todos os vizinhos com igual importância por defeito, é inerentemente enviesado para a classe mais populosa em cenários de desequilíbrio, necessitando de adaptações para melhorar a sua capacidade de reconhecer padrões na classe minoritária.



(1) + Info

(2) + Info

1

2

3

4

5

6


7

8

9

10


(1)



Métrica	Dataset Balanceado	Dataset Desbalanceado
Accuracy	0.795	0.994
Balanced Accuracy	0.501	0.625
Precision (macro)	0.492	0.847
Recall (macro)	0.501	0.625
F1-score (macro)	0.460	0.682

Embora o dataset desbalanceado tenha apresentado métricas mais altas, isso não indica melhor desempenho real. O valor extremamente alto de accuracy (99%) é enganador e ocorre porque o modelo está a prever quase exclusivamente a classe majoritária, o que é comum em datasets fortemente desbalanceados. As métricas macro (Precision, Recall e F1-score), que calculam o desempenho de forma igual para todas as classes, mostram que mesmo com valores mais altos no dataset desbalanceado, há uma clara penalização no reconhecimento das classes minoritárias, o Recall e o F1-score continuam relativamente baixos.

(2)




Métrica	Iris (Balanceado)	MC1 (Desbalanceado)
Accuracy	0.967	0.994
Balanced Accuracy	0.967	0.625
Precision (macro)	0.967	0.847
Recall (macro)	0.967	0.625
F1-score (macro)	0.967	0.682

O KNN apresenta um bom desempenho no dataset balanceado, refletido em métricas altas em todas as categorias. No entanto, no dataset desbalanceado, o KNN tende a favorecer a classe majoritária, resultando em um desempenho inferior para as classes minoritárias, o que é evidenciado pela queda nas métricas de Balanced Accuracy, Recall e F1-score.

Proposta: motivação

Conforme discutido anteriormente, o algoritmo KNN standard exibe uma tendência natural para favorecer a classe majoritária em datasets desequilibrados. Esta limitação resulta numa baixa sensibilidade para a classe minoritária, o que é problemático em muitas aplicações do mundo real onde a correta identificação de instâncias minoritárias é crucial (e.g., detecção de fraude, diagnóstico médico). A motivação para a nossa proposta reside na necessidade de mitigar este viés intrínseco do KNN. Pretendemos desenvolver uma variante do algoritmo que seja mais equitativa na sua capacidade de classificação, ajustando o seu processo de decisão para dar uma consideração mais apropriada à classe minoritária.



KNN Ponderado pela Distância

A Fase 1 demonstrou a sensibilidade do KNN às características dos dados que influenciam a distância (escala, valores discrepantes, desequilíbrio). No KNN padrão, todos os vizinhos dentro do 'k' contam igualmente. Ao ponderar a contribuição de cada vizinho com base em sua distância (por exemplo, ponderação inversa da distância), vizinhos mais próximos têm mais influência na previsão do que os mais distantes. Espera-se que essa modificação torne o algoritmo mais robusto por meio de:

- Redução do impacto de valores discrepantes;
- Melhoria do desempenho em regiões com densidade variável ou sobreposição de classes

Implementar a variante proposta: Em vez de simplesmente tomar a classe mais comum (voto majoritário), o método deve calcular um voto ponderado para cada classe.

KNN com Thresholding

Cada voto do vizinho é ponderado inversamente à frequência da sua classe. Ou seja, classes mais raras têm mais peso por vizinho.

Exemplo prático: Se a classe 1 ocorre só em 10% dos dados, o voto de um vizinho da classe 1 vale 10x mais do que o de um da classe 0.

No KNN tradicional, uma amostra é classificada como pertencente a uma determinada classe se essa classe obtiver a maioria dos votos (normalmente, mais de 50%). No KNN com thresholding, esse limiar é ajustado para ser menor do que 50% para a classe minoritária (por exemplo, 40%). Isso significa que a classe minoritária precisa de menos votos ponderados para ser considerada a classe da nova amostra. Essa "vantagem" extra é crucial para aumentar a chance de a classe minoritária ser corretamente identificada, o que é especialmente importante em casos onde a detecção da minoria é crítica (como em diagnóstico de doenças raras ou detecção de fraudes).

Comparação entre KNN básico e KNN ponderado por distância


O gráfico compara o desempenho dos classificadores KNN básico e KNN ponderado pelas distâncias em 11 datasets distintos, usando a balanced accuracy média como métrica de avaliação.

Observações principais:

- Em geral, ambas as variantes de KNN apresentam desempenhos muito semelhantes.
- O KNN ponderado obteve ligeiras melhorias em alguns datasets.
- Contudo, também apresentou desempenho ligeiramente inferior noutros datasets
- Em datasets como 'synthetic_control' e 'challenger', não houve qualquer diferença nos resultados, ambos os métodos atingiram exatamente a mesma balanced accuracy.

Conclusão:


Apesar da motivação teórica por detrás do uso de pesos baseados na distância (atribuir mais importância aos vizinhos mais próximos), os resultados empíricos mostram que o impacto na performance foi mínimo nestes datasets. A escolha entre KNN básico e ponderado pode, portanto, depender mais da natureza dos dados do que de uma vantagem clara e generalizada.



Comparação entre KNN Básico, Ponderado e com Thresholding

Com base nos resultados de Balanced Accuracy obtidos em 11 datasets distintos, é possível tirar as seguintes conclusões:

- KNN com Thresholding destacou-se como o método com melhor desempenho geral, superando os demais em 9 dos 11 datasets.
- Demonstrou ganhos expressivos, especialmente em:
 - 'dataset_1000_hypothyroid' (de ~0.65 para ~0.75)
 - 'dataset_1002_ipums_la_98-small' (de ~0.56 para ~0.69)
 - 'dataset_1021_page-blocks' (de ~0.79 para ~0.97)
 - 'dataset_949_arsenic-female-bladder' (de ~0.57 para ~0.67)
- KNN Ponderado, embora melhore ligeiramente o desempenho do KNN básico em quase todos os datasets, não conseguiu superar o método com thresholding em nenhum dos casos.
- KNN Básico, apesar da sua simplicidade, mostrou-se competitivo em datasets com classes bem separadas (e.g., 'dataset_1004_synthetic_control.csv' e 'dataset_1022_mfeat-pixel.csv'), mas foi geralmente superado pelas abordagens aprimoradas.
- Em datasets com elevada separabilidade de classes, como 'dataset_1004_synthetic_control.csv' e 'dataset_1022_mfeat-pixel.csv', todos os métodos atingem valores quase perfeitos de Balanced Accuracy, tornando as diferenças entre eles pouco significativas.



Comparação entre KNN Básico, Ponderado e com Thresholding

- Em datasets desafiantes ou desbalanceados, o método com thresholding demonstrou ser mais adaptável e sensível à distribuição das classes, apresentando os maiores ganhos relativos.
- O KNN com thresholding revela-se como a estratégia mais eficaz e robusta entre as três avaliadas, com a melhor acurácia média e menor variabilidade de desempenho. Ao ajustar a decisão com base na proporção ponderada de votos e um limiar controlado, consegue adaptar-se melhor a situações de desbalanceamento ou ruído.
- Embora o KNN Ponderado ofereça pequenas melhorias sobre o modelo básico, o seu impacto é limitado quando comparado com os benefícios do thresholding. Por sua vez, o KNN Básico pode ser suficiente em cenários com separação clara entre classes, mas tende a ser superado em contextos mais desafiantes.
- Em suma, thresholding é uma técnica promissora para melhorar classificadores KNN em ambientes complexos, especialmente quando o objetivo é reduzir o viés das classes dominantes ou lidar com padrões atípicos.

Método	Média	Desvio Padrão
KNN Básico	0.7528	± 0.0393
KNN Ponderado	0.7574	± 0.0409
KNN com Threshold	0.8126	± 0.0318

Teste de hipóteses

- Statistic = 4.000, p-value = 0.0166
- Adotando um nível de significância de 5 %, temos:
 - $p = 0.0166 < 0.05$
- Logo, rejeitamos a hipótese nula de que não há diferença entre os métodos.

Conclusão:

- A melhora de performance (balanced accuracy) do KNN com thresholding em relação ao KNN básico é estatisticamente significativa.
- Isso reforça que o ajuste do limiar de decisão (threshold) é uma técnica eficaz para reduzir o viés em cenários desbalanceados.